

광 고 · 가 짜 후 기 를 걸 러 낸 동 네 커피 가 이 드

동네 커피 노트

서비스 종합 가이드

리뷰의 바다에서 광고·협찬·무관·동명·나열식 글을 걸러내고, 규칙 엔진과 Claude AI가 진짜 방문 후기만 가려낸 수도권 카페 가이드. 모든 숫자에는 출처·근거가 함께 붙습니다.

목차

1	서비스 개요와 핵심 차별점(해자)
2	절대 원칙 (헌법)
3	화면 구성
4	데이터 소스 (전부 합법)
5	카페 수집 기준 — 무엇을 넣고 무엇을 뺀다
6	리뷰 품질 검증 엔진 (해자의 심장)
7	신뢰 등급 · 데이터 항목 · 성격/취향 축
8	에이전트 (자동화 두뇌)
9	검색 엔진 (의미 + AI 맥락 + 캐시)
10	자동화 스케줄
11	기술 스택 · 전체 데이터 흐름

한 문장 요약

"별점 말고 검증된 후기로 고른다." — 합법 공개 후기에서 옥석만 가려, 소비자에게 믿을 카페를, 사장님에게 검증 데이터 기반 경쟁력 진단을 제공하는 데이터 카페 가이드.

1. 서비스 개요와 핵심 차별점

커피를 아는 사람이 안내하는, 데이터 기반 동네 카페 가이드. 수도권(서울·경기·인천)의 동네 로스터리·개성 카페 중심.

무엇이 다른가 — 해자(moat)

카카오맵·블로그의 **별점·광고 후기**는 믿기 어렵습니다. 이 서비스의 핵심은 "**리뷰의 바다에서 옥석만 가리는 검증 엔진**"입니다. 수천 개 공개 후기에서 다음을 걸러냅니다.

- 나열식 "맛집 N곳 모음"에 이름만 끼인 글
- 카페명만 스치고 내용 없는 글 · 일반 교양/정보글
- 다른 지역·다른 지점의 **동명(同名)** 카페 글
- 광고·협찬·체험단 글

남은 **진짜 방문 후기**만 합성·집계·노출하며, 모든 판정에 사람이 읽을 수 있는 **근거(reason)**를 남깁니다(투명성 = 신뢰).

2단 검증 — ① 규칙 엔진(결정적·무료·빠름, 추적 가능)으로 1차 노이즈 제거 → ② **Claude Sonnet**이 글 내용·맥락을 한 건씩 읽어 최종 심사(놓친 진짜 후기 구제 + 규칙이 잘못 통과시킨 거짓양성 제거).

두 사용자

소비자	광고 없는 진짜 후기로 고른 내 동네 카페 · "느낌"으로 찾는 검색 · 지도·취향 매칭
사장님	검증된 후기로 보는 내 카페 경쟁력 — 동네 순위·성격·구성·리뷰 주기·데이터 기반 액션 플랜(관리자 인증)

현재 규모

수록 카페	약 2,970곳 (서울 25구 · 경기 31시군 · 인천 8)
공개 카페	약 1,990곳 (검증·참고 등급만 공개, 발굴 등급은 비공개 보관)
재고	0 — 직접 제조·판매 아님. 순수 큐레이션·정보 서비스

2. 절대 원칙 (헌법)

코드 한 줄, 데이터 한 건도 어기지 않는 최상위 규칙. 모든 기능이 여기에 종속됩니다.

원칙	내용
① 환각 절대 금지	지어낸 정보는 제품의 죽음. 모든 카페 정보는 추적 가능한 출처가 있어야 한다. 근거 없으면 "데이터 부족"으로 정직히 표시. 2개 이상 독립 소스에서 반복된 신호만 채택, 단일·광고성은 버린다. 출력에 근거(리뷰 N건 중 X회)를 함께 보존.
② 합법성 (타협 불가)	약관·저작권 위반 수집(스크래핑) 금지. 합법 소스만: 네이버·구글 공개 검색 API, 카페 자발 공개, 사장님 직접 등록. 외부 이미지 무단 사용 금지. 개인정보 수집·표시 금지 (위치는 대략적 지역만, ≈500m로 뭉뚱그려 익명 저장).
③ 품질 극대화	한 소스가 막히면 다른 합법 소스로 메운다(다중 소스 합성). 기술·약관 한계는 포기 사유가 아니라 개선 과제.
④ 최신성 우선	카페는 원두·메뉴·사장·분위기가 자주 바뀐다. 수집 시 날짜를 확보하고 최근 신호에 가중. 정기 재수집(갱신) 구조를 전제로 설계.
⑤ 뻥찬 답 금지	사장님 인사이트는 그 카페 데이터에서만 나오는 구체적 액션이어야. "맛"이 아니라 "리뷰에서 자주 언급되는 결" — 측정값인 척 과장 금지.

LLM의 역할 경계 — AI(Claude·Gemini)는 **선별·설명·검증**만 한다. 가격·평점·점수 같은 숫자를 **생성하지 않는다**. 모든 수치는 DB의 수집·계산값에서만 나온다.

3. 화면 구성

화면	구성·기능
랜딩 초기 화면	"소비자 / 사장님" 분리 진입. 사장님은 관리자 비밀번호 인증(세션 유지). 해자를 한눈에 전달하는 카피.
홈 / 잡지형 1면	지역 선택 시 그 동네판. 헤드라인 2개(가장 많이 이야기된 곳 / 커피에 진심인 집) + 코너(리뷰 많은 Top3·스페셜티 픽·새로 발견). 각 카드에 "선정 이유" 항상 표시. 느낌으로 검색 (🔍) · 내 위치 로 우리 동네 보기.
지도 /	Leaflet + CartoDB Voyager. 지역·카테고리 필터로 핀·목록 동적 렌더. 취향(성격) 매칭 하이라이트. "위치 보기" 핀 고정.
카페 상세 패널	결(성격) 태그 · 리뷰 종합 분석(정체성) · 옥석 통계 ("공개 글 N건 검증 → 노이즈 X건 제거 → 옥석 K건") · 근거 후기 (인용+출처+날짜, 검증/참고/🌟 AI검증 배지).
사장님 분석 /owner 관리자 인증	카페 검색 → 동네 순위(bar)·성격(radar)·구성(pie) 3탭 + 리뷰 주기 (최근 12개월) + 데이터 기반 액션 플랜 (차별점·빈 포지션·매물점·보완점·순위 전략).
사장님 등록 /cafe/register	사장님이 직접 카페 정보·보강 등록(1순위 발굴 대상).
관리자 /admin	KPI · 등급 분포 · 리뷰 검증 엔진 현황 (원본 수집%·AI 판정%·노이즈 제거율) · 방문자 통계·차트.

4. 데이터 소스 — 전부 합법

스크래핑·약관 위반 없음. 공식 API와 자발 공개 채널만 사용.

소스	용도	비고
네이버 지역검색 API local.json	카페 발굴	키워드×지역 검색, 상호·주소·좌표·업종. display=5, 댓글순.
네이버 블로그/카페글 API blog:cafearticle	후기 수집	제목+요약 스니펫(원문 복제 금지, 인용+링크+날짜만). display=100(쿼터 동일, 후기 ~5배). 일일 25,000 한도.
YouTube Data API v3 무료 쿼터	영상 후기	카페 영상 검색 → 제목·설명·상위 댓글 + 영상 링크·게시일. 자막/원문은 합법 불가 → 텍스트까지만. ▶YouTube 링크로 연결. 일 10,000유닛.
구글 Places API 기본 OFF	(미사용)	호출당 과금이라 기본 비활성 . 네이버·유튜브·블로그로 대체. 필요 시 ENABLE_GOOGLE_PLACES=1.
공공데이터포털 상가정보 data.go.kr (선택)	발굴 보완	등록 '커피전문점/카페' + 위경도 직접 제공. 네이버가 놓친 카페 보완(인증키 필요).
Google Gemini gemini-embedding-001	의미 검색	카페·질문을 768차원 벡터로 → 코사인 유사도. "느낌" 검색.
Claude Sonnet claude-sonnet-4-5	판정·검색	리뷰 맥락 최종 심사(구독·로컬 배치) + 검색 질문 맥락 이해(콘솔 키·실시간).

원본 보존(감사·재현) — 수집한 모든 후기 원본을 raw_reviews 에 저장. 재합성·재판정 시 API 재호출 없이 그대로 재현(쿼터 절약·결과 재현성). 쿼터/오류로 수집 실패 시엔 기존 데이터를 덮어쓰지 않고 보존한다.

5. 카페 수집 기준

무엇을 수록하고 무엇을 제외하는가 — 명확한 규칙.

✓ 포함

- 동네 소규모 카페 + 스페셜티(로스터리·핸드드립·싱글오리진·개성 카페)
- 지역 범위: 수도권만 — 서울 25개 구·경기 31개 시·군·인천 8개 구·군
- 스페셜티 체인은 유지(대형 저가 프랜차이즈만 제외)

✗ 제외

대형 프랜차이즈 상호에 아래 브랜드 포함 시 제외 (약 45개):

스타벅스

투썸

이디야

메가커피

빽다방

컴포즈

커피빈

할리스

엔제리너스

파스쿠찌

탐앤탐스

폴바셋

드롭탑

요거프레소

더벤티

매머드

공차

카페베네

만랩

토프레소

셀렉토

더리터

달콤커피

백억커피

쥬씨

... 외

비(非)카페 상호·업종에 정육·마트·편의점·치킨·피자·분식·국밥·노래·PC방·학원·병원·은행 등 포함 시 제외
중복 이름(공백 제거) + 좌표 근사(위도×1000 반올림) 동일 시 한 건만

발굴 키워드 (20개 · 지역마다 순회)

로스터리

스페셜티커피

직접로스팅

핸드드립

싱글오리진

자가배전

드립커피전문점

에스프레소바

커피 맛집

동네카페

작은카페

감성카페

디저트카페

베이커리카페

브런치카페

분위기좋은카페

조용한카페

루프탑카페

북카페

빈티지카페

적재 후 흐름 — 발굴된 카페는 우선 비공개로 저장 → 후기 수집·합성·검증을 거쳐 검증/참고 등급이면 자동 공개, 후기가 부족(발굴 등급)하면 비공개로 보관(없는 후기를 지어내지 않음). 후기가 적은 "숨은 집"은 약점이 아니라 희소가치·사장님 등록 1순위로 전환.

6. 리뷰 품질 검증 엔진 — 해자의 심장

각 후기를 4가지로 판정: 검증 참고 탈락 경계→AI 재판정

① 출처별 1차 처리

- 구글 리뷰

장소에 직접 달린 실방문 리뷰라 신뢰 → 내용량만 본다. 본문 ≥15자 검증, ≥8자 참고, 그 미만 탈락.
- 블로그/카페글

주제성 + 내용성 + 관련성 3가지를 본다(아래).

② 하드 탈락 규칙 (명백한 노이즈)

조건	판정
제목·본문에 카페명(구별 토큰)이 전혀 없음	탈락(무관/동명) — 단, 방문·구체 맥락이 뚜렷하면 경계 로 보존해 AI 재판정
제목에 수도권 밖 도시(충주·부산·대구 등) + 대상 지역어 없음	탈락 — 다른 지역 동명 카페
제목에 다른 시·군·구 + 대상 지역 언급 없음	탈락 — 같은 상호 다른 지점
"~란 무엇/하는 법/효능" 등 일반 교양·정보글	탈락 — 그 카페 후기가 아님
"맛집 N곳·추천·모음·투어" 나열식(제목 패턴 또는 본문에 가게 토큰 4개+)	탈락 — 주제가 분산된 모음글
방문 단서·구체 경험·평가가 하나도 없음	탈락 — 언급만

※ '구별 토큰' = 카페명에서 일반어(카페·커피·점)·지역어를 뺀 고유 식별어. 예: "을지로 문덕카페" → 문덕. 흔한 단어 이름이 무관 글에 우연히 걸리는 것을 막기 위해, 토큰만 일치할 땐 '카페 맥락어'나 지역이 함께 있어야 주제로 인정.

③ 투명 점수화 (0~100)

가점	점수	감점	점수
제목이 이 카페 (주제 글)	+42	나열식 모음 성격	-22
제목에 카페명 일부	+30	긴 글에 한 번만 스침	-16
본문에 카페명 언급	+14	광고/협찬 신호	-10
실제 방문 단서	+24	해시태그 과다(홍보성)	-8
구체 후기 신호(맛·분위기·메뉴…)	최대 +24	내용 짧음(<25자)	-10
지역 일치 / 긴 본문	+8 / +5		

최종 판정

검증 점수 ≥60 **그리고** 제목에 카페명 **그리고** (방문 또는 구체 신호) | 참고 점수 ≥38 + (제목 또는 본문에 카페명) | 그 외 탈락.

→ 검증은 '제목이 그 카페가 주제'인 글로 한정(본문에 스친 글은 내용이 좋아도 참고까지). 합성·집계엔 옥석(검증+참고)만 사용하며 검증분에 가중.

6+ Sonnet 최종 심사 (2단 검증)

규칙은 1차 필터. **Claude Sonnet**이 규칙을 통과한 후보 전체를 다시 읽어 최종 결정한다.

양방향 정밀도

구제(rescue) 카페명이 글자 그대로 없어도 내용·맥락(지역·분위기·메뉴·방문 경험)이 그 카페를 가리키면 → 살림

거짓양성 제거 규칙은 통과했지만 실제로 "가는 길·주차·영업시간" 정보글 등 도움 안 되는 글 → 제거

심사 기준 두 축: **about**(그 카페를 실제 방문해 쓴 글인가) · **helpful**(맛·분위기·메뉴 등 구체 경험이 담겨 도움되는가). 둘 다 참인 글만 통과. 판정이 애매하면 보수적으로 제외.

왜 Sonnet인가 — 규칙은 빠르고 투명하지만 글자 매칭의 한계가 있다. Sonnet은 사람처럼 **내용·맥락**을 읽어 "단어만 겹친 무관 글"과 "이름은 안 나와도 진짜 그 카페 후기"를 구분한다. 통과한 후기에는 화면에 ✨ **AI 검증** 배지가 붙는다.

실행 방식 (비용·정책)

리뷰 판정은 **실시간이 아니라 배치(백그라운드)**다. 그래서 사장님 본인 컴퓨터에서 **Claude Max** 구독으로 매일 돌린다 (추가 API 비용 0). 웹앱(Vercel)은 LLM을 호출하지 않고 **판정된 결과만** 서빙한다. 토큰 만료·실패 시엔 규칙 결과를 그대로 유지(무회귀).

7. 신뢰 등급 · 데이터 항목 · 축

신뢰 등급 (옥석 리뷰 수 기준)

등급	기준(검증+참고 리뷰 수)	의미·노출
검증	30건 이상	신호 충분 — 공개. 헤드라인·추천 우선.
참고	5 ~ 30건	참고 가능 — 공개.
발굴	5건 미만	데이터 부족 — 비공개 보관(숨은 집·사장님 등록 1순위).

출처별 합성 가중: 블로그 직접후기 1.2 · 구글 1.0 · 기타 0.7. (검증 통과분에만 적용)

성격 축 (char_scores) — 6개

검증 통과 리뷰 본문에서의 언급 빈도(측정값 아님). 취향 매칭·"결" 태그·레이더 차트의 기반.

축	리뷰에서 잡는 키워드
🔥 직접로스팅	로스팅·로스터리·직접 볶·자가배전·스페셜티·싱글오리진
📖 작업·공부	작업·노트북·공부·콘센트·집중·와이파이
💙 조용·혼자	조용·차분·혼자·고요·사색·한적
🍰 디저트	디저트·케이크·스콘·크로플·티라미수·베이커리·쿠키·빵
🛋️ 분위기	분위기·예쁜·감성·인테리어·사진·뷰·루프탑·아늑
🏠 넓은공간	넓·대형·규모·테라스·주차

취향 좌표 (맛)

산미(acidity)·바디(body)·단맛(sweet) — 리뷰의 긍/부정 맥락을 보정해 추정. **2건 이상 교차검증된 축만** 좌표화하고, 부족하면 비워 둔다(지어내지 않음).

그 외 저장 항목

synth_identity(리뷰 종합 정체성 문장) · synth_reviews(근거 후기 인용 최대 6개) · review_dates(검증 리뷰 게시일 → 리뷰 주기 분석) · synth_quality(원본/노이즈/옥석 통계) · cafe_snapshots(검증 리뷰 수·최근 90일 버즈 주간 스냅샷 → 모멘텀, 우리 소유 데이터).

8. 에이전트 (자동화 두뇌)

에이전트	역할	실행
발굴	네이버 지역검색으로 동네·스페셜티 카페 수집. 프랜차이즈·비카페·중복 제외 후 비공개 적재.	Vercel cron
상가정보 발굴	공공데이터(상가정보)로 누락 카페 보완(키 필요).	수동/예약
원본 예열	raw 캐시가 빈 카페의 후기를 새로 수집해 저장(쿼터 효율, 소진 시 자동 중단).	로컬 00:10
다중 소스 수집	네이버 블로그/카페글 + 유튜브(영상·댓글) 수집 → 영상 1개=스니펫 1개, 출처 링크 보존(▶YouTube).	cron/예열
합성/품질 엔진	수집 후기를 검증 엔진에 통과 → 등급·정체성·성격 축·취향 좌표·근거 후기 산출·저장.	cron/예열
Sonnet 판정	규칙 통과 후보를 Claude Sonnet이 맥락 최종 심사 → 양질만 공개(🌟 AI검증).	로컬 04:00
검색	의미(임베딩)로 후보 압축 → Sonnet이 질문 맥락 보고 선별·정렬(캐시).	요청 시
임베딩	카페 텍스트를 벡터화(신규·갱신분) → 의미 검색용.	Vercel 07:00
스냅샷	검증 리뷰 수·최근 버즈 주간 기록(소유 데이터) → 급상승(모멘텀) 분석.	Vercel 주간
사장님 인사이트	동네(구) 분포와 비교해 백분위 점수·순위·빈 포지션·액션 플랜 산출.	요청 시

설계 철학 — "사람이 발로 뛰어 채운다"는 틀을 깨고, AI의 강점(대량 데이터 통합·패턴 추출)으로 한 사람이 불가능한 규모를 자동으로 채우고 검증한다. 매일 돌수록 정확도가 누적 상승.

9. 검색 엔진

"비 오는 날 혼자 조용히 책 읽기 좋은 곳"처럼 사전에 없는 **느낌**으로도 찾게 한다.

3단 구조

- ① **의미(임베딩)** 질문을 벡터로 → 미리 임베딩된 카페와 코사인 유사도. 생성형 LLM 없이도 의미를 매칭(거의 공짜·항상 켜짐).
- ② **키워드·개념** 질문 토큰과 느낌(조용·작업·디저트...)을 카페 텍스트·검증 리뷰에서 직접 매칭, 근거 노출.
- ③ **AI 맥락 재정렬** 압축한 후보를 Claude Sonnet이 질문 의도로 선별·정렬, 질문에 답하는 한국어 이유 부착(콘솔 키 있을 때).

비용을 묶는 캐시

사람들의 질문은 무한해 보여도 실제로는 비슷한 것("조용한", "데이트", "작업")에 몰린다. **(질문 + 지역)별로 결과를 캐시** (12시간)해, 같은·비슷한 질문은 임베딩·LLM 재계산 없이 즉시 응답.

→ 비용은 **"방문자 수"가 아니라 "서로 다른 질문 수"**만큼만. 흔한 질문은 한 번만 계산하고 모두가 캐시를 공유. 키가 없으면 의미 검색으로 자동 폴백(무회귀).

데이터는 DB 실제값만 사용(점수·등급 환각 금지). LLM은 어떤 카페가 맞는지 고르고 이유를 말할 뿐, 없는 카페를 지어내지 않는다.

10. 자동화 스케줄

로컬 (사장님 컴퓨터 · launchd) — Claude Max 구독

시각(KST)	작업
매일 00:10	원본 예열 — 네이버 쿼터 리셋 직후, raw 캐시가 빈 카페 후기 수집
매일 04:00	Sonnet 판정 — 채워진 카페를 맥락 심사 → ✨ AI검증 · 공개 전환

클라우드 (Vercel cron)

시각(KST)	작업
매일 03:00	발굴 + 합성(cron-grow) — 새 지역 발굴 + 오래된 카페 재합성
매일 07:00	임베딩(cron-embed) — 신규 · 갱신 카페 벡터화(판정 이후라 최신 반영)
월요일 13:00	재수집(cron-resynth) — 최신성 위해 오래된 카페 원본 갱신
일요일 13:00	스냅샷(cron-snapshot) — 검증 리뷰 수 · 최근 버즈 기록(모멘텀, 소유 데이터)

【00:10】 예열 (raw 수집) → 【03:00】 발굴+규칙합성 → 【04:00】 Sonnet 최종심사 → 【07:00】 임베딩

쿼터 효율 노이즈 1차 제거 옥석만 공개+✨ 배지 의미검색 갱신


로컬 작업은 컴퓨터가 켜져 있을 때 실행(잠자기면 다음 깨어났을 때 보충). 매일 돌수록 검증 커버리지가 누적 상승.

11. 기술 스택 · 전체 데이터 흐름

스택

프론트·API	Next.js 16 (App Router · TypeScript · Tailwind · Turbopack), Vercel 배포
DB	Neon Postgres + pgvector(임베딩). 로컬·프로덕션 동일 DB 공유
지도·차트	Leaflet(CartoDB Voyager) · Recharts(bar/radar/pie/area)
AI	Claude Sonnet(판정·검색) · Google Gemini(임베딩)

한 카페가 화면에 오르기까지



맷음 — 이 서비스의 가치는 "데이터의 양"이 아니라 "리뷰의 바다에서 옥석을 가리는 검증 엔진"과, 그 위에 쌓이는 신뢰입니다. 모든 판정은 추적 가능한 근거를 남기고, AI는 선별·설명만 하며 숫자는 지어내지 않습니다.